

Máquinas de soporte vectorial

Héctor Selley

Universidad Anáhuac México

28 de junio de 2023

- 1 ¿Qué son las máquinas de soporte vectorial?
- 2 Descripción General
- 3 Clasificación
- 4 Problemas desbalanceados
- 5 Regresión
- 6 Funciones kernel
- 7 Bibliografía

¿Qué son las SVM?

Las máquinas de soporte vectorial (SVM) son un conjunto de métodos de aprendizaje supervisado utilizados para:

¿Qué son las SVM?

Las máquinas de soporte vectorial (SVM) son un conjunto de métodos de aprendizaje supervisado utilizados para:

¿Qué son las SVM?

Las máquinas de soporte vectorial (SVM) son un conjunto de métodos de aprendizaje supervisado utilizados para:

- Clasificación

¿Qué son las SVM?

Las máquinas de soporte vectorial (SVM) son un conjunto de métodos de aprendizaje supervisado utilizados para:

- Clasificación
- Regresión

¿Qué son las SVM?

Las máquinas de soporte vectorial (SVM) son un conjunto de métodos de aprendizaje supervisado utilizados para:

- Clasificación
- Regresión
- Detección de outliers

Ventajas de las SVM

Algunas ventajas de las máquinas de soporte vectorial son:

Ventajas de las SVM

Algunas ventajas de las máquinas de soporte vectorial son:

- Muy efectivas en espacios de alta dimensión.

Ventajas de las SVM

Algunas ventajas de las máquinas de soporte vectorial son:

- Muy efectivas en espacios de alta dimensión.
- Efectivas en los casos donde el número de las dimensiones sea mayor que el número de muestras.

Ventajas de las SVM

Algunas ventajas de las máquinas de soporte vectorial son:

- Muy efectivas en espacios de alta dimensión.
- Efectivas en los casos donde el número de las dimensiones sea mayor que el número de muestras.
- Utiliza un subconjunto de puntos de entrenamiento en la función decisión (llamados soporte vectorial), por lo que es eficiente en uso de memoria.

Ventajas de las SVM

Algunas ventajas de las máquinas de soporte vectorial son:

- Muy efectivas en espacios de alta dimensión.
- Efectivas en los casos donde el número de las dimensiones sea mayor que el número de muestras.
- Utiliza un subconjunto de puntos de entrenamiento en la función decisión (llamados soporte vectorial), por lo que es eficiente en uso de memoria.
- Versatilidad: Se pueden especificar diferentes *funciones kernel* para la función de decisión. Existe un conjunto de kernels común pero se puede utilizar uno personalizado.

Desventajas de las SVM

Algunas desventajas de las máquinas de soporte vectorial son:

Desventajas de las SVM

Algunas desventajas de las máquinas de soporte vectorial son:

- Si el número de características es mucho mayor que el número de muestras, es crucial evitar un sobreajuste al elegir las funciones kernel y el término de regularización.

Desventajas de las SVM

Algunas desventajas de las máquinas de soporte vectorial son:

- Si el número de características es mucho mayor que el número de muestras, es crucial evitar un sobreajuste al elegir las funciones kernel y el término de regularización.
- SVM's no proporcionan directamente la estimación de probabilidad, éstas se calculan utilizando una costosa validación cruzada de cinco pliegues.

¿Qué son las máquinas de soporte vectorial?

- Las máquinas de soporte vectorial en *scikit-learn* soportan como entrada el *vector de muestra denso* y el *vector de muestra escaso*.

¿Qué son las máquinas de soporte vectorial?

- Las máquinas de soporte vectorial en *scikit-learn* soportan como entrada el *vector de muestra denso* y el *vector de muestra escaso*.
- Sin embargo, para utilizar una SVM para realizar predicciones para un conjunto de datos escasos, se debe realizar un ajuste a esos datos.

¿Qué son las máquinas de soporte vectorial?

- Las máquinas de soporte vectorial en *scikit-learn* soportan como entrada el *vector de muestra denso* y el *vector de muestra escaso*.
- Sin embargo, para utilizar una SVM para realizar predicciones para un conjunto de datos escasos, se debe realizar un ajuste a esos datos.
- Para un desempeño óptimo, se debe utilizar una matriz C-ordered tipo *numpy.ndarray* (denso) o *scipy.sparse.csr_matrix* (escaso).

Contenido

- 1 ¿Qué son las máquinas de soporte vectorial?
- 2 Descripción General**
- 3 Clasificación
- 4 Problemas desbalanceados
- 5 Regresión
- 6 Funciones kernel
- 7 Bibliografía

- 1 **Selección del tipo de SVM:** Primero, debes decidir si utilizarás una SVM para clasificación o regresión. Las SVM para clasificación se utilizan para separar las muestras en diferentes clases, mientras que las SVM para regresión se utilizan para predecir valores continuos.

Descripción General

- 1 **Selección del tipo de SVM:** Primero, debes decidir si utilizarás una SVM para clasificación o regresión. Las SVM para clasificación se utilizan para separar las muestras en diferentes clases, mientras que las SVM para regresión se utilizan para predecir valores continuos.
- 2 **Preprocesamiento de datos:** Prepara tus datos de entrenamiento y asegúrate de que estén en un formato adecuado. Esto puede implicar la normalización, estandarización o cualquier otro tipo de procesamiento necesario para garantizar una representación adecuada de las características.

Descripción General

- 1 **Selección del tipo de SVM:** Primero, debes decidir si utilizarás una SVM para clasificación o regresión. Las SVM para clasificación se utilizan para separar las muestras en diferentes clases, mientras que las SVM para regresión se utilizan para predecir valores continuos.
- 2 **Preprocesamiento de datos:** Prepara tus datos de entrenamiento y asegúrate de que estén en un formato adecuado. Esto puede implicar la normalización, estandarización o cualquier otro tipo de procesamiento necesario para garantizar una representación adecuada de las características.
- 3 **Selección de características:** Si tienes muchas características en tus datos, puedes utilizar técnicas de selección o extracción de características para reducir su dimensión y mejorar el rendimiento del modelo SVM.

- 4 **Entrenamiento:** Durante la fase de entrenamiento, la SVM busca encontrar el hiperplano óptimo que mejor separe las muestras de diferentes clases. Este hiperplano se elige de manera que maximice la distancia (margen) entre las muestras de entrenamiento más cercanas de diferentes clases. Las muestras de entrenamiento más cercanas al hiperplano se llaman vectores de soporte.

- 4 **Entrenamiento:** Durante la fase de entrenamiento, la SVM busca encontrar el hiperplano óptimo que mejor separe las muestras de diferentes clases. Este hiperplano se elige de manera que maximice la distancia (margen) entre las muestras de entrenamiento más cercanas de diferentes clases. Las muestras de entrenamiento más cercanas al hiperplano se llaman vectores de soporte.
- 5 **Selección del kernel:** El kernel es una función que mapea los datos de entrada a un espacio de mayor dimensionalidad donde es más fácil separar las clases. Los kernels comunes utilizados en SVM incluyen el lineal, polinómico, radial basis function (RBF) y el sigmoidal. La elección del kernel depende de la naturaleza de los datos y la complejidad del problema.

- 6 **Ajuste de parámetros:** Las SVM tienen parámetros que deben ajustarse, como el parámetro de regularización (C) y el parámetro del kernel. Estos parámetros afectan el equilibrio entre la clasificación correcta de los datos de entrenamiento y la capacidad de generalización del modelo. Es importante ajustar estos parámetros mediante técnicas de validación cruzada para obtener un modelo óptimo.

- 6 **Ajuste de parámetros:** Las SVM tienen parámetros que deben ajustarse, como el parámetro de regularización (C) y el parámetro del kernel. Estos parámetros afectan el equilibrio entre la clasificación correcta de los datos de entrenamiento y la capacidad de generalización del modelo. Es importante ajustar estos parámetros mediante técnicas de validación cruzada para obtener un modelo óptimo.
- 7 **Clasificación o predicción:** Una vez entrenado el modelo SVM, puedes utilizarlo para clasificar nuevos datos en el caso de SVM para clasificación, o para predecir valores continuos en el caso de SVM para regresión. El modelo asignará las nuevas muestras a una clase específica o proporcionará una estimación numérica según corresponda.

Descripción General

- Es importante destacar que las SVM son algoritmos muy potentes y versátiles

Descripción General

- Es importante destacar que las SVM son algoritmos muy potentes y versátiles
- pero también pueden requerir un ajuste cuidadoso de parámetros y un preprocesamiento adecuado de los datos para obtener los mejores resultados.

Descripción General

- Es importante destacar que las SVM son algoritmos muy potentes y versátiles
- pero también pueden requerir un ajuste cuidadoso de parámetros y un preprocesamiento adecuado de los datos para obtener los mejores resultados.
- Además, pueden ser computacionalmente costosos en conjuntos de datos grandes.

Contenido

- 1 ¿Qué son las máquinas de soporte vectorial?
- 2 Descripción General
- 3 Clasificación**
- 4 Problemas desbalanceados
- 5 Regresión
- 6 Funciones kernel
- 7 Bibliografía

Clasificación

Para llevar a cabo una clasificación se puede utilizar:

Para llevar a cabo una clasificación se puede utilizar:

- SVC

Para llevar a cabo una clasificación se puede utilizar:

- SVC
- NuSVC

Para llevar a cabo una clasificación se puede utilizar:

- SVC
- NuSVC
- LinearSVC

SVC: Clasificación de Vector de Soporte-C. El tiempo de ajuste escala al menos cuadráticamente con el número de muestras y puede ser impráctico si se tienen decenas de miles de muestras.

- SVC: Clasificación de Vector de Soporte-C. El tiempo de ajuste escala al menos cuadráticamente con el número de muestras y puede ser impráctico si se tienen decenas de miles de muestras.
- NuSVC: Clasificación de Vector de Soporte-Nu. Similar a SVC pero utiliza un parámetro para controlar el número de vectores de soporte.





- SVC: Clasificación de Vector de Soporte-C.** El tiempo de ajuste escala al menos cuadráticamente con el número de muestras y puede ser impráctico si se tienen decenas de miles de muestras.
- NuSVC: Clasificación de Vector de Soporte-Nu.** Similar a SVC pero utiliza un parámetro para controlar el número de vectores de soporte.
- LinearSVC: Clasificación de Vector de Soporte Lineal.** Similar a SVC pero tiene mayor flexibilidad en la elección de funciones de penalización y pérdida, por lo que debería escalar mejor para un conjunto muy grande de muestras.

Clasificación

Dichas clases realizan una clasificación binaria y multiclase en un conjunto de datos.

Clasificación

Dichas clases realizan una clasificación binaria y multiclase en un conjunto de datos.



- **SVC** y **NuSVC** son métodos similares pero aceptan conjuntos de parámetros ligeramente diferentes (diversos) y tienen diferentes formulaciones matemáticas.

- **SVC** y **NuSVC** son métodos similares pero aceptan conjuntos de parámetros ligeramente diferentes (diversos) y tienen diferentes formulaciones matemáticas.
- **LinearSVC** es una implementación más rápida de la clasificación de vector de soporte (SVC) con kernel lineal.

- **SVC** y **NuSVC** son métodos similares pero aceptan conjuntos de parámetros ligeramente diferentes (diversos) y tienen diferentes formulaciones matemáticas.
- **LinearSVC** es una implementación más rápida de la clasificación de vector de soporte (SVC) con kernel lineal.
- La función de decisión SVM depende de un subconjunto del conjunto de entrenamiento, llamado **vector de soporte**.

Contenido

- 1 ¿Qué son las máquinas de soporte vectorial?
- 2 Descripción General
- 3 Clasificación
- 4 Problemas desbalanceados**
- 5 Regresión
- 6 Funciones kernel
- 7 Bibliografía

- SVM puede dar más importancia a ciertas clases o a ciertas muestras individuales


Problemas desbalanceados

- SVM puede dar más importancia a ciertas clases o a ciertas muestras individuales
- Esto se llama peso de clase o peso de muestra.

Problemas desbalanceados


- SVM puede dar más importancia a ciertas clases o a ciertas muestras individuales
- Esto se llama peso de clase o peso de muestra.
- La figura ilustra el perímetro de decisión de un problema desbalanceado, con y sin corrección de peso.

Problemas desbalanceados




Problemas desbalanceados

Constant weights



Modified weights



Contenido

- 1 ¿Qué son las máquinas de soporte vectorial?
- 2 Descripción General
- 3 Clasificación
- 4 Problemas desbalanceados
- 5 Regresión**
- 6 Funciones kernel
- 7 Bibliografía

- El método de soporte vectorial puede extenderse para resolver problemas de regresión

- El método de soporte vectorial puede extenderse para resolver problemas de regresión:
Regresión de Vectores de Soporte

- El método de soporte vectorial puede extenderse para resolver problemas de regresión:
Regresión de Vectores de Soporte
- El modelo producido por la clasificación de vectores de soporte depende únicamente de un subconjunto del conjunto de entrenamiento

- El método de soporte vectorial puede extenderse para resolver problemas de regresión:
Regresión de Vectores de Soporte
- El modelo producido por la clasificación de vectores de soporte depende únicamente de un subconjunto del conjunto de entrenamiento
- Esto debido a que la función costo para la construcción del modelo no toma en cuenta puntos que se encuentran más allá del margen.

Existen tres diferentes implementaciones de la Regresión de Vectores de Soporte.

Existen tres diferentes implementaciones de la Regresión de Vectores de Soporte.

SVR: Regresión de Vectores de Soporte-Epsilon La complejidad del tiempo de ajuste es más que cuadrática con el número de muestras, lo que dificulta escalar a conjuntos de datos con más de un par de 10000 muestras.

Existen tres diferentes implementaciones de la Regresión de Vectores de Soporte.

SVR: Regresión de Vectores de Soporte-Epsilon La complejidad del tiempo de ajuste es más que cuadrática con el número de muestras, lo que dificulta escalar a conjuntos de datos con más de un par de 10000 muestras.

NuSVR: Regresión de Vectores de Soporte-Nu Similar a NuSVC, para la regresión, usa un parámetro ν para controlar la cantidad de vectores de soporte. Sin embargo, a diferencia de NuSVC, donde ν reemplaza a C , aquí ν reemplaza el parámetro epsilon de epsilon-SVR.

Regresión

Existen tres diferentes implementaciones de la Regresión de Vectores de Soporte.

SVR: Regresión de Vectores de Soporte-Epsilon La complejidad del tiempo de ajuste es más que cuadrática con el número de muestras, lo que dificulta escalar a conjuntos de datos con más de un par de 10000 muestras.

NuSVR: Regresión de Vectores de Soporte-Nu Similar a NuSVC, para la regresión, usa un parámetro ν para controlar la cantidad de vectores de soporte. Sin embargo, a diferencia de NuSVC, donde ν reemplaza a C , aquí ν reemplaza el parámetro epsilon de epsilon-SVR.

LinearSVR: Regresión de Vectores de Soporte Lineal Similar a SVR con el parámetro $\text{kernel}='linear'$, tiene más flexibilidad en la elección de penalizaciones y funciones de pérdida y debería escalar mejor a un gran número de muestras.

- LinearSVR es más rápido que SVR pero solo considera el caso lineal

- LinearSVR es más rápido que SVR pero solo considera el caso lineal
- NuSVR implementa una formulación matemática ligeramente diferente que SVR y LinearSVR.

Contenido

- 1 ¿Qué son las máquinas de soporte vectorial?
- 2 Descripción General
- 3 Clasificación
- 4 Problemas desbalanceados
- 5 Regresión
- 6 Funciones kernel**
- 7 Bibliografía

Funciones kernel

Las funciones kernel más comunes son las siguientes:

Funciones kernel

Las funciones kernel más comunes son las siguientes:

- Lineal

Funciones kernel

Las funciones kernel más comunes son las siguientes:

- Lineal
- Polinomial

Funciones kernel

Las funciones kernel más comunes son las siguientes:

- Lineal
- Polinomial
- RBF (Función de Base Radial)

Funciones kernel

Las funciones kernel más comunes son las siguientes:

- Lineal
- Polinomial
- RBF (Función de Base Radial)
- Sigmoide

- Cuando se entrena un SVM con kernel SBF se deben considerar dos parámetros: C y γ .

- Cuando se entrena un SVM con kernel SBF se deben considerar dos parámetros: C y γ .
- C compensa la clasificación errónea de las muestras de entrenamiento contra la simplicidad de la superficie de decisión

- Cuando se entrena un SVM con kernel SBF se deben considerar dos parámetros: C y γ .
- C compensa la clasificación errónea de las muestras de entrenamiento contra la simplicidad de la superficie de decisión
- Un valor bajo de C suaviza la superficie de decisión, mientras que un valor alto de C pretende clasificar correctamente todos los ejemplos de entrenamiento.

- Cuando se entrena un SVM con kernel SBF se deben considerar dos parámetros: C y γ .
- C compensa la clasificación errónea de las muestras de entrenamiento contra la simplicidad de la superficie de decisión
- Un valor bajo de C suaviza la superficie de decisión, mientras que un valor alto de C pretende clasificar correctamente todos los ejemplos de entrenamiento.
- γ define cuánta influencia tiene una sola muestra de entrenamiento.

- Cuando se entrena un SVM con kernel SBF se deben considerar dos parámetros: C y γ .
- C compensa la clasificación errónea de las muestras de entrenamiento contra la simplicidad de la superficie de decisión
- Un valor bajo de C suaviza la superficie de decisión, mientras que un valor alto de C pretende clasificar correctamente todos los ejemplos de entrenamiento.
- γ define cuánta influencia tiene una sola muestra de entrenamiento.
- Cuanto mayor sea γ , más cerca deben estar otras muestras para verse afectadas.

Contenido

- 1 ¿Qué son las máquinas de soporte vectorial?
- 2 Descripción General
- 3 Clasificación
- 4 Problemas desbalanceados
- 5 Regresión
- 6 Funciones kernel
- 7 Bibliografía**

References I



Lars Buitinck, Gilles Louppe, Mathieu Blondel, Fabian Pedregosa, Andreas Mueller, Olivier Grisel, Vlad Niculae, Peter Prettenhofer, Alexandre Gramfort, Jaques Grobler, Robert Layton, Jake VanderPlas, Arnaud Joly, Brian Holt, and Gaël Varoquaux.

API design for machine learning software: experiences from the scikit-learn project.

In *ECML PKDD Workshop: Languages for Data Mining and Machine Learning*, pages 108–122, 2013.



F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay.

Scikit-learn: Machine learning in Python.

Journal of Machine Learning Research, 12:2825–2830, 2011.